



概率论与数理统计

相关结论及其证明

AUTHOR LiH

CONTACT lihow@stu.xmu.edu.cn



前言

参考教材:《概率论与数理统计(第五版)》

ISBN: 9787040516609

只从考试的角度来看,概统只需要掌握结论并应用即可,但是这样在做一些涉及到原理的题目可能会比较吃亏。因此,本 pdf 主要对相关结论(第一章的内容和高中的知识联系较紧密,这里不再讨论)给出较为详细的证明,内容可能比较啰嗦且涉及到课本之外的理论,已经掌握原理或只想记结论的同学请跳着阅读,以减轻负担。同时由于时间比较赶,证明过程中可能有笔误或其他错误,如果阅读中有觉得不对的地方,请联系封面邮箱改正。

另外,概统后面可能会用到各种概率分布函数,如果有同学不想查表的话,可以载 geogebra, 选择概率计算器。

官网: <https://www.geogebra.org/>

国内镜像: <https://ggb123.cn/>

目录

1 主要结论及证明	1
1.1 各种分布以及相关结论	1
1.2 随机变量(一维、二维)相关	6
1.3 第四章相关	10
2 例题	14
2.1 各种分布的可加性	14
2.2 随机变量的函数的分布	17
2.3 边缘分布和条件分布	21
2.4 最大值、最小值分布	23



1 主要结论及证明

1.1 各种分布以及相关结论

1. 0-1 分布与二项分布

0-1 分布(特殊的二项分布)

- 期望: $E(X) = p$
- 方差: $D(X) = p(1 - p)$

二项分布 $X \sim b(n, p)$ 或 $X \sim B(n, p)$

- 分布律: $P(X = k) = C_n^k p^k (1 - p)^{n-k}, \quad k = 0, 1, 2, \dots, n$
- 期望: $E(X) = np$
- 方差: $D(X) = np(1 - p)$

证明提示 将 X 看成 n 个独立同分布的 0-1 分布变量 X_i 的和, 即 $X = \sum_{i=1}^n X_i$ 。由于期望和方差(独立前提下)具有可加性, 因此 $E(X) = \sum E(X_i) = np$, 且 $D(X) = \sum D(X_i) = np(1 - p)$ 。

2. 泊松分布

引理 1.1 指数函数的麦克劳林展开

对于任意实数 λ , 指数函数 e^λ 可以展开为幂级数, 这是推导泊松分布数字特征的核心基础:

$$e^\lambda = \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = 1 + \lambda + \frac{\lambda^2}{2!} + \dots$$

$X \sim \pi(\lambda)$ 或 $X \sim P(\lambda)$

- 分布律: $P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}$, $k = 0, 1, 2, \dots$
- 泊松定理(二项分布的极限): 当 $n \geq 20, p \leq 0.05$ 时, 有近似公式 $C_n^k p^k (1-p)^{n-k} \approx \frac{\lambda^k}{k!} e^{-\lambda}$, 其中 $\lambda = np$ 。

期望与方差的证明

首先求期望 $E(X)$:

$$E(X) = \sum_{k=0}^{\infty} k \cdot \frac{\lambda^k}{k!} e^{-\lambda} = e^{-\lambda} \sum_{k=1}^{\infty} k \cdot \frac{\lambda^k}{k(k-1)!} = e^{-\lambda} \cdot \lambda \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} = e^{-\lambda} \cdot \lambda \cdot e^\lambda = \lambda$$

接着求 $E(X^2)$, 这里的核心技巧是利用 $k^2 = k(k-1) + k$ 进行拆项:

$$\begin{aligned} E(X^2) &= \sum_{k=0}^{\infty} k^2 \frac{\lambda^k}{k!} e^{-\lambda} = \sum_{k=1}^{\infty} (k(k-1) + k) \frac{\lambda^k}{k!} e^{-\lambda} \\ &= \sum_{k=2}^{\infty} k(k-1) \frac{\lambda^k}{k!} e^{-\lambda} + \sum_{k=1}^{\infty} k \frac{\lambda^k}{k!} e^{-\lambda} \\ &= \lambda^2 e^{-\lambda} \sum_{k=2}^{\infty} \frac{\lambda^{k-2}}{(k-2)!} + E(X) \\ &= \lambda^2 e^{-\lambda} \cdot e^\lambda + \lambda = \lambda^2 + \lambda \end{aligned}$$

最后计算方差:

$$D(X) = E(X^2) - [E(X)]^2 = (\lambda^2 + \lambda) - \lambda^2 = \lambda$$

3. 几何分布与超几何分布

引理 1.2 幂级数逐项求导

对于无穷等比级数 $\sum_{k=1}^{\infty} q^k = \frac{q}{1-q}$ (其中 $|q| < 1$), 在收敛域内可以逐项求导。即:

$$\sum_{k=1}^{\infty} kq^{k-1} = \frac{1}{(1-q)^2}$$

同理, 对上式再次求导可得:

$$\sum_{k=2}^{\infty} k(k-1)q^{k-2} = \frac{2}{(1-q)^3}$$

几何分布

- 分布律: $P(X = k) = (1-p)^{k-1}p, \quad k = 1, 2, 3, \dots$
- 期望与方差: $E(X) = \frac{1}{p}, \quad D(X) = \frac{1-p}{p^2}$

期望与方差的证明

令 $q = 1 - p$ 。利用上述引理, 直接代入可得期望:

$$E(X) = \sum_{k=1}^{\infty} k \cdot q^{k-1}p = p \sum_{k=1}^{\infty} kq^{k-1} = p \cdot \frac{1}{(1-q)^2} = p \cdot \frac{1}{p^2} = \frac{1}{p}$$

求方差时, 先求 $E[X(X-1)]$:

$$E[X(X-1)] = \sum_{k=1}^{\infty} k(k-1)q^{k-1}p = pq \sum_{k=2}^{\infty} k(k-1)q^{k-2} = pq \cdot \frac{2}{(1-q)^3} = pq \cdot \frac{2}{p^3} = \frac{2q}{p^2}$$

$$D(X) = E[X(X-1)] + E(X) - [E(X)]^2 = \frac{2(1-p)}{p^2} + \frac{1}{p} - \frac{1}{p^2} = \frac{1-p}{p^2}$$

引理 1.3 组合数恒等式

在组合数学中, 有以下两个常用于概率论推导的重要恒等式:

- 吸收恒等式: $kC_M^k = MC_{M-1}^{k-1}$, 同理 $k(k-1)C_M^k = M(M-1)C_{M-2}^{k-2}$ 。
- 范德蒙德卷积公式: $\sum_k C_A^k C_B^{n-k} = C_{A+B}^n$ 。

超几何分布 场景: N 件物品, 其中 M 件次品, 不放回地抽取 n 件。 X 表示抽到的次品数。

- 分布律: $P(X = k) = \frac{C_M^k \cdot C_{N-M}^{n-k}}{C_N^n}$, $k = 0, 1, 2, \dots, \min\{n, M\}$
- 期望: $E(X) = np$, 其中 $p = \frac{M}{N}$ 为次品率。
- 方差: $D(X) = np(1-p)\frac{N-n}{N-1}$, 其中 $p = \frac{M}{N}$ 为次品率。

期望与方差的证明

证明的核心在于利用引理中的吸收恒等式以及范德蒙德卷积公式。

$$\begin{aligned} E(X) &= \sum_{k=1}^n k \frac{C_M^k C_{N-M}^{n-k}}{C_N^n} = \sum_{k=1}^n \frac{M C_{M-1}^{k-1} C_{N-M}^{n-k}}{\frac{N}{n} C_{N-1}^{n-1}} \\ &= n \frac{M}{N} \sum_{k=1}^n \frac{C_{M-1}^{k-1} C_{(N-1)-(M-1)}^{(n-1)-(k-1)}}{C_{N-1}^{n-1}} \end{aligned}$$

由于后半部分的求和代表了在 $N-1$ 件物品中抽取 $n-1$ 件的所有概率之和, 其值等于 1。因此:

$$E(X) = n \frac{M}{N} = np$$

求方差同样先求 $E[X(X-1)]$:

$$\begin{aligned} E[X(X-1)] &= \sum_{k=2}^n k(k-1) \frac{C_M^k C_{N-M}^{n-k}}{C_N^n} = \sum_{k=2}^n \frac{M(M-1) C_{M-2}^{k-2} C_{N-M}^{n-k}}{\frac{N(N-1)}{n(n-1)} C_{N-2}^{n-2}} \\ &= \frac{n(n-1)M(M-1)}{N(N-1)} \sum_{k=2}^n \frac{C_{M-2}^{k-2} C_{(N-2)-(M-2)}^{(n-2)-(k-2)}}{C_{N-2}^{n-2}} \\ &= \frac{n(n-1)M(M-1)}{N(N-1)} \end{aligned}$$

最后代入方差公式化简(令 $p = \frac{M}{N}$):

$$\begin{aligned} D(X) &= E[X(X-1)] + E(X) - [E(X)]^2 \\ &= \frac{n(n-1)M(M-1)}{N(N-1)} + np - n^2 p^2 \\ &= np \left[\frac{(n-1)(M-1)}{N-1} + 1 - np \right] \\ &= np(1-p) \frac{N-n}{N-1} \end{aligned}$$

4. 指数分布

引理 1.4 分部积分法

在计算连续型随机变量(如指数分布、正态分布)的数字特征时,常利用分部积分法消去被积函数中的多项式因子:

$$\int u dv = uv - \int v du$$

$$X \sim E(\lambda)$$

也有参数化形式为 $\theta = \frac{1}{\lambda}$, 请根据任课老师要求记忆:

- 概率密度函数: $f(x) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}}, & x > 0 \\ 0, & \text{其他} \end{cases}$

- 分布函数: $F(x) = \begin{cases} 1 - e^{-\frac{x}{\theta}}, & x > 0 \\ 0, & \text{其他} \end{cases}$

无记忆性证明, 即证明 $P\{X > s+t \mid X > s\} = P\{X > t\}$:

$$\begin{aligned} P\{X > s+t \mid X > s\} &= \frac{P\{X > s+t \text{ 且 } X > s\}}{P\{X > s\}} = \frac{P\{X > s+t\}}{P\{X > s\}} \\ &= \frac{1 - F(s+t)}{1 - F(s)} = \frac{e^{-\frac{s+t}{\theta}}}{e^{-\frac{s}{\theta}}} = e^{-\frac{t}{\theta}} \\ &= 1 - F(t) = P\{X > t\} \end{aligned}$$

期望与方差的证明(利用分部积分法)

$$\begin{aligned} E(X) &= \int_0^{+\infty} x \cdot \frac{1}{\theta} e^{-\frac{x}{\theta}} dx = - \int_0^{+\infty} x d(e^{-\frac{x}{\theta}}) \\ &= - [xe^{-\frac{x}{\theta}}]_0^{+\infty} + \int_0^{+\infty} e^{-\frac{x}{\theta}} dx \\ &= 0 + [-\theta e^{-\frac{x}{\theta}}]_0^{+\infty} = \theta \end{aligned}$$

同理, 两次运用分部积分法求 $E(X^2)$:

$$\begin{aligned} E(X^2) &= \int_0^{+\infty} x^2 \cdot \frac{1}{\theta} e^{-\frac{x}{\theta}} dx = 2\theta^2 \\ D(X) &= E(X^2) - [E(X)]^2 = 2\theta^2 - \theta^2 = \theta^2 \end{aligned}$$

5. 均匀分布

$$X \sim U(a, b)$$

- 概率密度函数: $f(x) = \begin{cases} \frac{1}{b-a}, & a < x < b \\ 0, & \text{其他} \end{cases}$

期望与方差的证明

$$E(X) = \int_a^b x \cdot \frac{1}{b-a} dx = \frac{1}{b-a} \left[\frac{1}{2} x^2 \right]_a^b = \frac{b^2 - a^2}{2(b-a)} = \frac{a+b}{2}$$

求方差先求 $E(X^2)$:

$$E(X^2) = \int_a^b x^2 \cdot \frac{1}{b-a} dx = \frac{1}{b-a} \left[\frac{1}{3} x^3 \right]_a^b = \frac{b^3 - a^3}{3(b-a)} = \frac{1}{3}(a^2 + ab + b^2)$$

$$\begin{aligned} D(X) &= E(X^2) - [E(X)]^2 = \frac{a^2 + ab + b^2}{3} - \frac{(a+b)^2}{4} \\ &= \frac{4a^2 + 4ab + 4b^2 - 3(a^2 + 2ab + b^2)}{12} \\ &= \frac{a^2 - 2ab + b^2}{12} = \frac{1}{12}(b-a)^2 \end{aligned}$$

6. 正态分布

$$X \sim N(\mu, \sigma^2)$$

- 概率密度函数: $f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$
- 期望与方差: $E(X) = \mu, \quad D(X) = \sigma^2$

重要性质

- 标准正态分布对称性: 若 $X \sim N(0, 1)$, 则 $\Phi(x) + \Phi(-x) = 1$ 。
- 标准化变换: 若 $X \sim N(\mu, \sigma^2)$, 则 $\frac{X-\mu}{\sigma} \sim N(0, 1)$ 。

1.2 随机变量（一维、二维）相关

1. 一维随机变量的函数的分布

引理 1.5 复合函数与变上限积分求导法则

在推导随机变量函数的概率密度时,通常先求分布函数 $F_Y(y)$,再对其求导。对于形如 $F(y) = \int_{a(y)}^{b(y)} f(t)dt$ 的积分,其导数为:

$$F'(y) = f(b(y)) \cdot b'(y) - f(a(y)) \cdot a'(y)$$

经典例题:平方的分布 设连续型随机变量 X 的概率密度为 $f_X(x)$,求 $Y = X^2$ 的概率密度 $f_Y(y)$ 。

详细推导 首先求 Y 的分布函数 $F_Y(y)$ 。显然,当 $y < 0$ 时, $P\{X^2 \leq y\} = 0$ 。
当 $y \geq 0$ 时:

$$F_Y(y) = P\{Y \leq y\} = P\{X^2 \leq y\} = P\{-\sqrt{y} \leq X \leq \sqrt{y}\}$$

利用分布函数的定义,上式可以写为:

$$F_Y(y) = F_X(\sqrt{y}) - F_X(-\sqrt{y})$$

对 y 求导,利用复合函数求导法则,可得 Y 的概率密度函数:

$$\begin{aligned} f_Y(y) &= \frac{d}{dy} [F_X(\sqrt{y}) - F_X(-\sqrt{y})] \\ &= f_X(\sqrt{y}) \cdot \left(\frac{1}{2\sqrt{y}}\right) - f_X(-\sqrt{y}) \cdot \left(-\frac{1}{2\sqrt{y}}\right) \\ &= \frac{1}{2\sqrt{y}} [f_X(\sqrt{y}) + f_X(-\sqrt{y})] \end{aligned}$$

2. 二维随机变量

引理 1.6 分布函数与概率密度的微积分关系

对于二维连续型随机变量 (X, Y) ,其联合分布函数 $F(x, y)$ 与联合概率密度 $f(x, y)$ 满足:

$$F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) dv du \quad \text{且} \quad \frac{\partial^2 F(x, y)}{\partial x \partial y} = f(x, y)$$

边缘分布 (Marginal Distribution) 将联合分布中的另一个变量“积分掉”,即可得到边缘分布。

• 分布函数:

$$F_X(x) = \lim_{y \rightarrow +\infty} F(x, y) = \int_{-\infty}^x \left[\int_{-\infty}^{+\infty} f(t, y) dy \right] dt$$

- 概率密度函数及其推导: 对 $F_X(x)$ 两边关于 x 求导, 由微积分基本定理可得:

$$f_X(x) = \frac{d}{dx} \int_{-\infty}^x \left(\int_{-\infty}^{+\infty} f(t, y) dy \right) dt = \int_{-\infty}^{+\infty} f(x, y) dy$$

同理可证 $f_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx$ 。

条件分布 (Conditional Distribution)

- 离散型: $P\{X = x_i | Y = y_j\} = \frac{P\{X=x_i, Y=y_j\}}{P\{Y=y_j\}}$
- 连续型概率密度及其推导: 考虑在 $y < Y \leq y + \Delta y$ 的条件下, $X \leq x$ 的概率。当 $\Delta y \rightarrow 0$ 时, 利用极限和积分中值定理:

$$\begin{aligned} F_{X|Y}(x|y) &= \lim_{\Delta y \rightarrow 0} P\{X \leq x | y < Y \leq y + \Delta y\} \\ &= \lim_{\Delta y \rightarrow 0} \frac{P\{X \leq x, y < Y \leq y + \Delta y\}}{P\{y < Y \leq y + \Delta y\}} \\ &= \lim_{\Delta y \rightarrow 0} \frac{\int_{-\infty}^x \int_y^{y+\Delta y} f(u, v) dv du}{\int_y^{y+\Delta y} f_Y(v) dv} \approx \frac{\int_{-\infty}^x f(u, y) \Delta y du}{f_Y(y) \Delta y} = \int_{-\infty}^x \frac{f(u, y)}{f_Y(y)} du \end{aligned}$$

两边对 x 求导, 即得条件概率密度:

$$f_{X|Y}(x|y) = \frac{f(x, y)}{f_Y(y)} \quad (f_Y(y) > 0)$$

独立性 (Independence) 若 X 和 Y 相互独立, 则联合分布等于边缘分布的乘积:

- 离散型: $\forall x, y, \quad P\{X = x_i, Y = y_j\} = P\{X = x_i\} \cdot P\{Y = y_j\}$
- 任意型(分布函数): $F(x, y) = F_X(x) \cdot F_Y(y)$
- 连续型(概率密度): $f(x, y) = f_X(x) \cdot f_Y(y)$

3. 两个随机变量的函数的分布

引理 1.7 二维随机变量变换的雅可比行列式法

设 (X, Y) 的联合概率密度为 $f(x, y)$ 。作变换 $U = X, Z = g(X, Y)$, 若其存在唯一反函数 $x = u, y = h(u, z)$, 且偏导数连续, 则雅可比行列式(Jacobian)为:

$$J = \frac{\partial(x, y)}{\partial(u, z)} = \begin{vmatrix} \frac{\partial x}{\partial u} & \frac{\partial x}{\partial z} \\ \frac{\partial y}{\partial u} & \frac{\partial y}{\partial z} \end{vmatrix} = \begin{vmatrix} 1 & 0 \\ \frac{\partial y}{\partial u} & \frac{\partial y}{\partial z} \end{vmatrix} = \frac{\partial y}{\partial z}$$

变换后的联合概率密度为 $f_{U,Z}(u, z) = f(u, h(u, z)) \cdot |J|$ 。求 Z 的边缘密度只需对

u (即 x) 积分:

$$f_Z(z) = \int_{-\infty}^{+\infty} f(x, h(x, z)) \left| \frac{\partial y}{\partial z} \right| dx$$

(1) 和的分布 $Z = X + Y$

- 一般情况与证明: 由 $z = x + y$ 可得反函数 $y = z - x$ 。此时雅可比行列式 $J = \frac{\partial y}{\partial z} = 1$ 。代入引理公式直接得到:

$$f_Z(z) = \int_{-\infty}^{+\infty} f(x, z - x) \cdot |1| dx = \int_{-\infty}^{+\infty} f(x, z - x) dx$$

若 X, Y 相互独立, 则 $f(x, y) = f_X(x)f_Y(y)$, 可得卷积公式:

$$f_Z(z) = \int_{-\infty}^{+\infty} f_X(x) \cdot f_Y(z - x) dx = \int_{-\infty}^{+\infty} f_X(z - y) \cdot f_Y(y) dy$$

- 正态分布的可加性: 若 $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$ 且相互独立, 代入卷积公式并通过配方化简, 可证:

$$Z = X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$$

(2) 商与积的分布

- 商 $Z = \frac{Y}{X}$: 反函数为 $y = xz$ 。雅可比行列式 $J = \frac{\partial y}{\partial z} = x$ 。代入引理公式可证:

$$f_{Y/X}(z) = \int_{-\infty}^{+\infty} f(x, xz) \cdot |x| dx$$

- 积 $Z = XY$: 反函数为 $y = \frac{z}{x}$ 。雅可比行列式 $J = \frac{\partial y}{\partial z} = \frac{1}{x}$ 。代入引理公式可证:

$$f_{XY}(z) = \int_{-\infty}^{+\infty} f\left(x, \frac{z}{x}\right) \cdot \left|\frac{1}{x}\right| dx$$

(3) 最大值与最小值的分布 (重难点)

假设 X 和 Y 相互独立, 其分布函数分别为 $F_X(x)$ 和 $F_Y(y)$ 。

- 最大值分布 $M = \max\{X, Y\}$

推导: $M \leq z$ 意味着 X 和 Y 同时必须小于等于 z 。由独立性可得:

$$\begin{aligned} F_{\max}(z) &= P\{M \leq z\} = P\{\max\{X, Y\} \leq z\} \\ &= P\{X \leq z \text{ 且 } Y \leq z\} \\ &= P\{X \leq z\} \cdot P\{Y \leq z\} = F_X(z) \cdot F_Y(z) \end{aligned}$$

- 最小值分布 $N = \min\{X, Y\}$

推导: 直接求 $\min \leq z$ 比较困难, 我们转化为对立事件, 即 $\min > z$ 意味着 X 和 Y 同时必须大于 z 。

$$\begin{aligned} F_{\min}(z) &= P\{N \leq z\} = 1 - P\{N > z\} \\ &= 1 - P\{\min\{X, Y\} > z\} \\ &= 1 - P\{X > z \text{ 且 } Y > z\} \\ &= 1 - [P\{X > z\} \cdot P\{Y > z\}] \\ &= 1 - [(1 - F_X(z)) \cdot (1 - F_Y(z))] \end{aligned}$$

1.3 第四章相关

1. 切比雪夫不等式 (Chebyshev's Inequality)

引理 1.8 切比雪夫不等式的意义

切比雪夫不等式给出了在随机变量分布未知的情况下, 仅仅利用其期望和方差, 就能估算出随机变量偏离其期望值的概率上限。

设随机变量 X 的数学期望为 $E(X) = \mu$, 方差为 $D(X) = \sigma^2$, 则对于任意给定的正数 $\varepsilon > 0$, 有:

$$P\{|X - \mu| \geq \varepsilon\} \leq \frac{\sigma^2}{\varepsilon^2}$$

等价形式(对立事件):

$$P\{|X - \mu| < \varepsilon\} \geq 1 - \frac{\sigma^2}{\varepsilon^2}$$

证明 (以连续型随机变量为例, 离散型同理可证)

设 X 的概率密度函数为 $f(x)$, 根据方差的定义:

$$D(X) = \int_{-\infty}^{+\infty} (x - \mu)^2 f(x) dx$$

由于被积函数非负, 我们可以缩小积分区间, 去掉 $|x - \mu| < \varepsilon$ 的部分, 不等号依然成立:

$$D(X) \geq \int_{|x-\mu| \geq \varepsilon} (x - \mu)^2 f(x) dx$$

在积分区间 $|x - \mu| \geq \varepsilon$ 上, 显然有 $(x - \mu)^2 \geq \varepsilon^2$, 因此:

$$\begin{aligned} D(X) &\geq \int_{|x-\mu| \geq \varepsilon} \varepsilon^2 f(x) dx \\ &= \varepsilon^2 \int_{|x-\mu| \geq \varepsilon} f(x) dx \\ &= \varepsilon^2 P\{|X - \mu| \geq \varepsilon\} \end{aligned}$$

两边同除以 ε^2 , 即证得:

$$P\{|X - \mu| \geq \varepsilon\} \leq \frac{D(X)}{\varepsilon^2} = \frac{\sigma^2}{\varepsilon^2}$$

2. 协方差与相关系数

协方差 (Covariance) 的定义与计算公式:

$$\text{Cov}(X, Y) = E[X - E(X)][Y - E(Y)]$$

计算公式推导:

$$\begin{aligned}\text{Cov}(X, Y) &= E[XY - X \cdot E(Y) - Y \cdot E(X) + E(X)E(Y)] \\ &= E(XY) - E(X)E(Y) - E(Y)E(X) + E(X)E(Y) \\ &= E(XY) - E(X)E(Y)\end{aligned}$$

相关系数 (Correlation Coefficient) 的定义:

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{D(X)} \cdot \sqrt{D(Y)}}$$

方差的展开公式:

$$D(X + Y) = D(X) + D(Y) + 2\text{Cov}(X, Y)$$

证明:

$$\begin{aligned}D(X + Y) &= E\{[(X + Y) - E(X + Y)]^2\} \\ &= E\{[(X - E(X)) + (Y - E(Y))]^2\} \\ &= E\{[X - E(X)]^2 + [Y - E(Y)]^2 + 2[X - E(X)][Y - E(Y)]\} \\ &= D(X) + D(Y) + 2\text{Cov}(X, Y)\end{aligned}$$

协方差的性质及证明:

- 提取常数: $\text{Cov}(aX, bY) = ab \cdot \text{Cov}(X, Y)$

$$\text{证明: } \text{Cov}(aX, bY) = E[(aX - E(aX))(bY - E(bY))] = E[ab(X - E(X))(Y - E(Y))] = ab\text{Cov}(X, Y)$$

- 分配律: $\text{Cov}(X_1 + X_2, Y) = \text{Cov}(X_1, Y) + \text{Cov}(X_2, Y)$

不相关与独立的等价关系:

$$\rho_{XY} = 0 \iff X, Y \text{ 不相关} \iff \text{Cov}(X, Y) = 0 \iff E(XY) = E(X) \cdot E(Y)$$

引理 1.9 正态分布的特殊性

对于一般的随机变量, 独立必定不相关, 但不相关不一定独立。然而, 对于二维正态分布, 这两个概念是完全等价的。

当 (X, Y) 服从二维正态分布时:

$$X, Y \text{ 相互独立} \iff X, Y \text{ 不相关 (即 } \rho = 0 \text{)}$$

证明简述 若 X, Y 不相关, 即 $\rho = 0$, 代入二维正态分布的概率密度展开式中:

$$\begin{aligned} f(x_1, x_2) &= \frac{1}{2\pi\sigma_1\sigma_2} \exp \left\{ -\frac{1}{2} \left[\frac{(x_1 - \mu_1)^2}{\sigma_1^2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2} \right] \right\} \\ &= \left[\frac{1}{\sqrt{2\pi}\sigma_1} \exp \left(-\frac{(x_1 - \mu_1)^2}{2\sigma_1^2} \right) \right] \cdot \left[\frac{1}{\sqrt{2\pi}\sigma_2} \exp \left(-\frac{(x_2 - \mu_2)^2}{2\sigma_2^2} \right) \right] \\ &= f_{X_1}(x_1) \cdot f_{X_2}(x_2) \end{aligned}$$

联合概率密度等于边缘概率密度的乘积, 故 X, Y 相互独立。反之, 若独立, 协方差必为 0, 即 $\rho = 0$ 。

3. 矩与协方差矩阵

矩 (Moments) 的定义

- k 阶原点矩: $E(X^k)$
- k 阶中心矩: $E\{[X - E(X)]^k\}$
- $k + l$ 阶混合矩: $E(X^k Y^l)$
- $k + l$ 阶混合中心矩: $E\{[X - E(X)]^k \cdot [Y - E(Y)]^l\}$

二维正态分布与协方差矩阵设 $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, 则其相关系数 $\rho_{XY} = \rho$ 其协方差矩阵 C (或记为 Σ) 定义为:

$$C = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}$$


二维正态分布的概率密度函数有两种表示方法:

(1) 矩阵形式 (更具一般性, 易于向高维推广): 记均值向量 $\boldsymbol{\mu} = (\mu_1, \mu_2)^T$, 随机向量 $\mathbf{X} = (x_1, x_2)^T$, 则:

$$f(x_1, x_2) = \frac{1}{(2\pi) \cdot |C|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T C^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}$$

(2) 展开形式 (常用于代数计算):

$$f(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \cdot \exp \left\{ -\frac{1}{2(1-\rho^2)} \left[\frac{(x_1 - \mu_1)^2}{\sigma_1^2} - 2\rho \frac{(x_1 - \mu_1)(x_2 - \mu_2)}{\sigma_1\sigma_2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2} \right] \right\}$$



2 例题

2.1 各种分布的可加性

1. 常见分布的可加性总结

可加性(再生性)定义: 若随机变量 X 和 Y 相互独立, 且服从同一类型的分布(参数可以不同), 如果它们的和 $Z = X + Y$ 仍然服从该类型的分布, 则称该分布具有可加性。

分布类型	是否可加	前提条件 (相互独立)	结论
二项分布	是	成功率 p 必须相同	$B(n_1, p) + B(n_2, p) = B(n_1 + n_2, p)$
泊松分布	是	无特殊限制	$P(\lambda_1) + P(\lambda_2) = P(\lambda_1 + \lambda_2)$
正态分布	是	无特殊限制	$N(\mu_1, \sigma_1^2) + N(\mu_2, \sigma_2^2) = N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$
几何分布	否	即使 p 相同也不可加	和服从负二项分布 (巴斯卡分布)
指数分布	否	即使 λ 相同也不可加	和服从 Erlang 分布 (伽马分布特例)
均匀分布	否	即使区间相同也不可加	和服从分段函数 (如辛钦分布)

2. 经典例题与证明

例题 2.1 泊松分布的可加性证明

已知 $X \sim P(\lambda_1), Y \sim P(\lambda_2)$, 且 X 与 Y 相互独立。证明 $Z = X + Y \sim P(\lambda_1 + \lambda_2)$ 。

解答 利用离散型随机变量和的分布公式(离散卷积):

$$P(Z = n) = P(X + Y = n) = \sum_{k=0}^n P(X = k)P(Y = n - k)$$

代入泊松分布的概率质量函数:

$$\begin{aligned} P(Z = n) &= \sum_{k=0}^n \frac{\lambda_1^k}{k!} e^{-\lambda_1} \cdot \frac{\lambda_2^{n-k}}{(n-k)!} e^{-\lambda_2} \\ &= e^{-(\lambda_1 + \lambda_2)} \sum_{k=0}^n \frac{1}{k!(n-k)!} \lambda_1^k \lambda_2^{n-k} \end{aligned}$$

为了凑出二项式展开, 我们在求和号内外同乘除 $n!$:

$$\begin{aligned} P(Z = n) &= e^{-(\lambda_1 + \lambda_2)} \frac{1}{n!} \sum_{k=0}^n \frac{n!}{k!(n-k)!} \lambda_1^k \lambda_2^{n-k} \\ &= e^{-(\lambda_1 + \lambda_2)} \frac{1}{n!} \sum_{k=0}^n C_n^k \lambda_1^k \lambda_2^{n-k} \end{aligned}$$

利用二项式定理 $(a + b)^n = \sum_{k=0}^n C_n^k a^k b^{n-k}$, 上式可化简为:

$$P(Z = n) = \frac{(\lambda_1 + \lambda_2)^n}{n!} e^{-(\lambda_1 + \lambda_2)}$$

这正是参数为 $\lambda_1 + \lambda_2$ 的泊松分布的分布律, 得证。

例题 2.2 二项分布可加性的条件探究

已知 $X \sim B(n_1, p), Y \sim B(n_2, p)$, 且 X, Y 相互独立。证明 $Z = X + Y \sim B(n_1 + n_2, p)$ 。如果两者的 p 不同, 还具有可加性吗?

解答 第一部分: 证明可加性 (p 相同)

物理意义法(推荐): X 表示在 n_1 次独立重复试验中成功的次数, Y 表示在额外的 n_2 次独立重复试验中成功的次数, 每次成功率均为 p 。那么 $X + Y$ 显然表示在总共 $n_1 + n_2$ 次独立重复试验中成功的总次数, 这严格符合二项分布的定义, 即 $Z \sim B(n_1 + n_2, p)$ 。

代数法(离散卷积):

$$\begin{aligned}
 P(Z = k) &= \sum_{i=0}^k P(X = i)P(Y = k - i) \\
 &= \sum_{i=0}^k [C_{n_1}^i p^i (1-p)^{n_1-i}] \cdot [C_{n_2}^{k-i} p^{k-i} (1-p)^{n_2-(k-i)}] \\
 &= p^k (1-p)^{n_1+n_2-k} \sum_{i=0}^k C_{n_1}^i C_{n_2}^{k-i}
 \end{aligned}$$

根据范德蒙德卷积公式 $\sum_{i=0}^k C_{n_1}^i C_{n_2}^{k-i} = C_{n_1+n_2}^k$, 代入即得 $B(n_1 + n_2, p)$ 的分布律。

第二部分: p 不同时不可加的反例

若 $X \sim B(1, p_1)$, $Y \sim B(1, p_2)$, $p_1 \neq p_2$ 。 $Z = X + Y$ 可能取值为 $0, 1, 2$ 。

$$P(Z = 2) = P(X = 1)P(Y = 1) = p_1 p_2$$

如果 Z 仍然服从二项分布, 设为 $B(2, p_3)$, 则必有 $P(Z = 2) = p_3^2$ 。这意味着 $p_3 = \sqrt{p_1 p_2}$ 。但同时 $E(Z) = E(X) + E(Y) = p_1 + p_2$ 。如果 $Z \sim B(2, p_3)$, 其期望应为 $2p_3 = 2\sqrt{p_1 p_2}$ 。显然 $p_1 + p_2 \neq 2\sqrt{p_1 p_2}$ (除非 $p_1 = p_2$), 产生矛盾。故 p 不同时不可加。

例题 2.3 几何分布与指数分布不可加的反例

分别计算两个独立同分布的几何分布之和、以及两个独立同分布的指数分布之和, 说明它们为何不具有可加性。

解答 (1) 几何分布的反例:

设 $X, Y \sim Ge(p)$ 独立, 其分布律为 $P(X = k) = (1-p)^{k-1}p$ ($k \geq 1$)。考察 $Z = X + Y$, 显然 $Z \geq 2$ 。计算 $P(Z = k)$:

$$\begin{aligned}
 P(Z = k) &= \sum_{i=1}^{k-1} P(X = i)P(Y = k - i) \\
 &= \sum_{i=1}^{k-1} [(1-p)^{i-1}p] \cdot [(1-p)^{k-i-1}p] \\
 &= \sum_{i=1}^{k-1} p^2 (1-p)^{k-2} = (k-1)p^2 (1-p)^{k-2}
 \end{aligned}$$

由于 $P(Z = k)$ 的表达式中出现了系数 $(k-1)$, 这与几何分布的标准形式 $(1-p)^{k-1}p$ 完全不同(实际上它是负二项分布)。因此几何分布不具有可加性。

(2) 指数分布的反例(利用卷积公式):

设 $X, Y \sim E(\lambda)$ 独立, 概率密度为 $f(x) = \lambda e^{-\lambda x}$ ($x > 0$)。求 $Z = X + Y$ 的概率密度

$f_Z(z)$ 。当 $z > 0$ 时, 利用卷积公式:

$$\begin{aligned}f_Z(z) &= \int_0^z f_X(x)f_Y(z-x)dx \\&= \int_0^z (\lambda e^{-\lambda x}) \cdot (\lambda e^{-\lambda(z-x)})dx \\&= \int_0^z \lambda^2 e^{-\lambda z} dx \\&= \lambda^2 e^{-\lambda z} \int_0^z 1 dx = \lambda^2 z e^{-\lambda z}\end{aligned}$$

所得密度函数 $f_Z(z) = \lambda^2 z e^{-\lambda z}$ (此为伽马分布), 其中多出了变量 z 作为乘子, 显然不再是指数分布的形式。因此指数分布不具有可加性。

2.2 随机变量的函数的分布

1. 一维随机变量的函数的分布

例题 2.4 求 $Y = e^{-X}$ 的密度函数

已知连续型随机变量 X 具有密度函数:

$$f(x) = \begin{cases} 0.5e^{-x} + e^{-2x}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

求随机变量 $Y = e^{-X}$ 的密度函数 $f_Y(y)$ 。

解答 这里我们使用分布函数求导法。这种方法思路最清晰, 且利用复合函数求导可以免去求积分的麻烦。

第一步: 确定 Y 的取值范围

因为 $x > 0$, 且 $Y = e^{-X}$ 单调递减, 所以 Y 的取值范围是 $e^{-\infty} < Y < e^0$, 即 $0 < y < 1$ 。

第二步: 利用分布函数转化并直接求导

当 $0 < y < 1$ 时, 写出 Y 的分布函数 $F_Y(y)$:

$$\begin{aligned}F_Y(y) &= P\{Y \leq y\} = P\{e^{-X} \leq y\} \\&= P\{-X \leq \ln y\} = P\{X \geq -\ln y\} \\&= 1 - P\{X < -\ln y\} = 1 - F_X(-\ln y)\end{aligned}$$

对两边关于 y 直接求导, 利用复合函数求导法则, 即可直接得到密度函数 $f_Y(y)$:

$$\begin{aligned} f_Y(y) &= F'_Y(y) = \frac{d}{dy}[1 - F_X(-\ln y)] \\ &= -f_X(-\ln y) \cdot \frac{d}{dy}(-\ln y) \\ &= -f_X(-\ln y) \cdot \left(-\frac{1}{y}\right) \\ &= f_X(-\ln y) \cdot \frac{1}{y} \end{aligned}$$

第三步: 代入原密度函数计算

将 $x = -\ln y$ 代入原分布的密度函数 $f(x) = 0.5e^{-x} + e^{-2x}$ 中:

$$f_Y(y) = (0.5e^{-(-\ln y)} + e^{-2(-\ln y)}) \cdot \frac{1}{y}$$

利用对数恒等式 $e^{\ln y} = y$ 以及 $e^{2\ln y} = y^2$, 上式可进一步化简:

$$\begin{aligned} f_Y(y) &= (0.5y + y^2) \cdot \frac{1}{y} \\ &= 0.5 + y \end{aligned}$$

结论:

当 $y \notin (0, 1)$ 时, $f_Y(y) = 0$ 。因此, Y 的密度函数为:

$$f_Y(y) = \begin{cases} y + 0.5, & 0 < y < 1 \\ 0, & \text{其他} \end{cases}$$

2. 两个随机变量的函数的分布

例题 2.5 求 $Z = XY$ 的密度函数

已知二维连续型随机变量 (X, Y) 的密度函数如下:

$$f(x, y) = \begin{cases} x, & 1 \leq x \leq 2, \frac{1}{x} \leq y \leq \frac{2}{x} \\ 0, & \text{其他} \end{cases}$$

求 $Z = XY$ 的密度函数 $f_Z(z)$ 。

解答 根据两个随机变量的函数的分布定理, 设 $Z = g(X, Y) = XY$ 。
由题意知, 在 $f(x, y) \neq 0$ 的区域内 $1 \leq x \leq 2$, 所以 $x \neq 0$ 。

解出反函数 $y = h(x, z) = \frac{z}{x}$, 求偏导得到 $\frac{\partial h}{\partial z} = \frac{1}{x}$ 。

由于 $x > 0$, 所以雅可比因子的绝对值为:

$$\left| \frac{\partial h}{\partial z} \right| = \frac{1}{x}$$

代入定理公式:

$$f_Z(z) = \int_{-\infty}^{+\infty} f(x, h(x, z)) \left| \frac{\partial h}{\partial z} \right| dx = \int_{-\infty}^{+\infty} f\left(x, \frac{z}{x}\right) \frac{1}{x} dx$$

确定非零区间的积分上下限(核心步骤):

被积函数 $f\left(x, \frac{z}{x}\right)$ 不为零的条件是点 $\left(x, \frac{z}{x}\right)$ 必须落在原密度函数的非零区域内。代入原条件得:

$$\begin{cases} 1 \leq x \leq 2 \\ \frac{1}{x} \leq \frac{z}{x} \leq \frac{2}{x} \end{cases}$$

因为 $x > 0$, 我们将第二个不等式同时乘以 x , 得到关于 z 的范围:

$$1 \leq z \leq 2$$

此时, 这组条件变为: $1 \leq z \leq 2$ 且 $1 \leq x \leq 2$ 。

这说明, 当 z 取 $[1, 2]$ 中的任意值时, x 的积分区间始终是整个 $[1, 2]$, 并不受到 z 的耦合限制。

计算积分:

当 $1 \leq z \leq 2$ 时, 代入原密度函数 $f(x, y) = x$ (此时 y 的位置被 $\frac{z}{x}$ 替代, 但原函数表达式中并没有 y , 所以直接就是 x):

$$\begin{aligned} f_Z(z) &= \int_1^2 x \cdot \frac{1}{x} dx \\ &= \int_1^2 1 dx \\ &= [x]_1^2 = 2 - 1 = 1 \end{aligned}$$

当 z 不在 $[1, 2]$ 范围内时, $f_Z(z) = 0$ 。

结论:

$Z = XY$ 的密度函数为:

$$f_Z(z) = \begin{cases} 1, & 1 \leq z \leq 2 \\ 0, & \text{其他} \end{cases}$$

3. 二维分布函数与区域概率的直接积分

例题 2.6 求分布函数与区域概率

设二维随机变量 (X, Y) 具有概率密度

$$f(x, y) = \begin{cases} 2e^{-(2x+y)}, & x > 0, y > 0, \\ 0, & \text{其他.} \end{cases}$$

- (1) 求分布函数 $F(x, y)$;
- (2) 求概率 $P\{Y \leq X\}$ 。

解答

(1) 求分布函数 $F(x, y)$

根据二维分布函数的定义 $F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) dv du$ 。

当 $x \leq 0$ 或 $y \leq 0$ 时, 显然有 $F(x, y) = 0$ 。

当 $x > 0$ 且 $y > 0$ 时, 被积函数为 $f(u, v) = 2e^{-(2u+v)}$:

$$\begin{aligned} F(x, y) &= \int_0^x \int_0^y 2e^{-(2u+v)} dv du \\ &= \left(\int_0^x 2e^{-2u} du \right) \cdot \left(\int_0^y e^{-v} dv \right) \\ &= [-e^{-2u}]_0^x \cdot [-e^{-v}]_0^y \\ &= (1 - e^{-2x})(1 - e^{-y}) \end{aligned}$$

因此, 联合分布函数为:

$$F(x, y) = \begin{cases} (1 - e^{-2x})(1 - e^{-y}), & x > 0, y > 0 \\ 0, & \text{其他} \end{cases}$$

(2) 求概率 $P\{Y \leq X\}$ (利用二重积分直接求解)

要求 $P\{Y \leq X\}$, 我们不要求出 $Z = Y - X$ 的分布, 而是直接将条件 $Y \leq X$ 作为二重积分的积分区域 D 。

由题意, 联合密度非零的区域是第一象限 ($x > 0, y > 0$), 再结合条件 $y \leq x$, 积分区域 D

可以表示为: $0 < x < +\infty$ 且 $0 < y < x$ 。

$$\begin{aligned} P\{Y \leq X\} &= \iint_{y \leq x} f(x, y) dx dy \\ &= \int_0^{+\infty} \left(\int_0^x 2e^{-(2x+y)} dy \right) dx \\ &= \int_0^{+\infty} 2e^{-2x} [-e^{-y}]_0^x dx \\ &= \int_0^{+\infty} 2e^{-2x} (1 - e^{-x}) dx \\ &= \int_0^{+\infty} (2e^{-2x} - 2e^{-3x}) dx \\ &= \left[-e^{-2x} + \frac{2}{3}e^{-3x} \right]_0^{+\infty} \\ &= \lim_{x \rightarrow +\infty} \left(-e^{-2x} + \frac{2}{3}e^{-3x} \right) - \left(-e^0 + \frac{2}{3}e^0 \right) \\ &= 0 - \left(-1 + \frac{2}{3} \right) \\ &= \frac{1}{3} \end{aligned}$$

故 $P\{Y \leq X\} = \frac{1}{3}$ 。

2.3 边缘分布和条件分布

1. 二维随机变量的边缘与条件密度

例题 2.7 求解常数、边缘密度与条件密度

已知二维随机变量 (X, Y) 的概率密度函数为

$$f(x, y) = \begin{cases} \frac{1}{A}, & -1 \leq x \leq 1, 0 \leq y \leq x^2 \\ 0, & \text{其他} \end{cases}$$

其中 A 为常数。

- (i) 试求常数 A ;
- (ii) 求边缘概率密度 $f_Y(y)$;
- (iii) 求条件概率密度 $f_{X|Y}(x|y)$ 。

解答

- (i) 求常数 A

根据二维概率密度函数的归一性性质, 联合密度在整个平面的二重积分必须等于 1, 即 $\iint_{-\infty}^{+\infty} f(x, y) dx dy = 1$ 。

积分区域 D 为 $-1 \leq x \leq 1, 0 \leq y \leq x^2$ 。我们选择先对 y 积分, 后对 x 积分:

$$\begin{aligned}\iint_D \frac{1}{A} dx dy &= \frac{1}{A} \int_{-1}^1 \left(\int_0^{x^2} dy \right) dx \\ &= \frac{1}{A} \int_{-1}^1 x^2 dx \\ &= \frac{1}{A} \left[\frac{1}{3} x^3 \right]_{-1}^1 \\ &= \frac{1}{A} \left(\frac{1}{3} - \left(-\frac{1}{3} \right) \right) = \frac{2}{3A}\end{aligned}$$

令 $\frac{2}{3A} = 1$, 解得 $A = \frac{2}{3}$ 。

因此, 联合概率密度函数为:

$$f(x, y) = \begin{cases} \frac{3}{2}, & -1 \leq x \leq 1, 0 \leq y \leq x^2 \\ 0, & \text{其他} \end{cases}$$

(ii) 求边缘概率密度 $f_Y(y)$

由联合密度的非零区域 $0 \leq y \leq x^2 \leq 1$ 可知, Y 的可能取值范围是 $0 < y < 1$ 。

对于固定的 $y \in (0, 1)$, 要求原密度函数非零, 对应的 x 必须满足 $x^2 \geq y$ 且 $-1 \leq x \leq 1$ 。

解这个不等式, 得到 x 的范围是由两段区间组成的: $x \in [-1, -\sqrt{y}] \cup [\sqrt{y}, 1]$ 。

因此, 对 x 积分时需要分段:

$$\begin{aligned}f_Y(y) &= \int_{-\infty}^{+\infty} f(x, y) dx \\ &= \int_{-1}^{-\sqrt{y}} \frac{3}{2} dx + \int_{\sqrt{y}}^1 \frac{3}{2} dx \\ &= \frac{3}{2}(-\sqrt{y} - (-1)) + \frac{3}{2}(1 - \sqrt{y}) \\ &= \frac{3}{2}(1 - \sqrt{y}) + \frac{3}{2}(1 - \sqrt{y}) \\ &= 3(1 - \sqrt{y})\end{aligned}$$

当 y 不在 $(0, 1)$ 范围内时, $f_Y(y) = 0$ 。所以边缘概率密度为:

$$f_Y(y) = \begin{cases} 3(1 - \sqrt{y}), & 0 < y < 1 \\ 0, & \text{其他} \end{cases}$$

(iii) 求条件概率密度 $f_{X|Y}(x|y)$

根据条件概率密度的定义: $f_{X|Y}(x|y) = \frac{f(x, y)}{f_Y(y)}$ (当 $f_Y(y) > 0$ 时)。

对于给定的 $0 < y < 1$, 有 $f_Y(y) = 3(1 - \sqrt{y})$ 。将 $f(x, y)$ 和 $f_Y(y)$ 直接代入公式:

$$f_{X|Y}(x|y) = \frac{3/2}{3(1 - \sqrt{y})} = \frac{1}{2(1 - \sqrt{y})}$$

注意, 此条件密度有效的 x 范围即为原联合密度非零的区域(因为给定 y 的前提下, x 只能在特定的范围内取值), 即 $x \in [-1, -\sqrt{y}] \cup [\sqrt{y}, 1]$ 。

因此, 条件概率密度为:

$$f_{X|Y}(x|y) = \begin{cases} \frac{1}{2(1-\sqrt{y})}, & x \in [-1, -\sqrt{y}] \cup [\sqrt{y}, 1] \\ 0, & \text{其他} \end{cases}$$

2.4 最大值、最小值分布

1. 二维均匀分布的几何概型解法

例题 2.8 雷达屏幕上的均匀分布

雷达的圆形屏幕半径为 R , 设目标出现点 (X, Y) 在屏幕上服从均匀分布。

- (1) 求 $P\{Y > 0 \mid Y > X\}$;
- (2) 设 $M = \max\{X, Y\}$, 求 $P\{M > 0\}$ 。

解答

因为点 (X, Y) 在半径为 R 的圆 $D: x^2 + y^2 \leq R^2$ 上服从均匀分布, 所以这是一个典型的几何概型问题。对于圆内的任意区域 G , 点落在 G 内的概率等于 G 的面积与圆面积的比值, 即 $P((X, Y) \in G) = \frac{S_G}{\pi R^2}$ 。

(1) 求 $P\{Y > 0 \mid Y > X\}$

根据条件概率公式:

$$P\{Y > 0 \mid Y > X\} = \frac{P\{Y > 0, Y > X\}}{P\{Y > X\}}$$

首先计算分母 $P\{Y > X\}$:

区域 $Y > X$ 是直线 $y = x$ 上方的半圆。根据对称性, 其面积正好是整个圆面积的一半, 因此:

$$P\{Y > X\} = \frac{1}{2}$$

接着计算分子 $P\{Y > 0, Y > X\}$:

该事件要求点同时满足 $y > 0$ (在 x 轴上方) 和 $y > x$ (在直线 $y = x$ 上方)。

在极坐标系下, $y > 0$ 对应角度 $\theta \in (0, \pi)$, $y > x$ 对应角度 $\theta \in (\frac{\pi}{4}, \frac{5\pi}{4})$ 。

两者的交集为 $\theta \in (\frac{\pi}{4}, \pi)$ 。这个扇形的圆心角为 $\pi - \frac{\pi}{4} = \frac{3\pi}{4}$ ，占整个圆周角 2π 的 $\frac{3}{8}$ 。因此：

$$P\{Y > 0, Y > X\} = \frac{3}{8}$$

代入条件概率公式：

$$P\{Y > 0 \mid Y > X\} = \frac{3/8}{1/2} = \frac{3}{4}$$

(2) 求 $P\{M > 0\}$

已知 $M = \max\{X, Y\}$ 。直接求 $M > 0$ 比较复杂，我们可以利用对立事件来转化：

$$P\{M > 0\} = 1 - P\{M \leq 0\}$$

而最大值小于等于 0，意味着两个变量同时小于等于 0：

$$P\{M \leq 0\} = P\{\max\{X, Y\} \leq 0\} = P\{X \leq 0, Y \leq 0\}$$

区域 $X \leq 0, Y \leq 0$ 正好是圆在第三象限的部分。显然，它的面积是整个圆面积的 $\frac{1}{4}$ 。因此：

$$P\{X \leq 0, Y \leq 0\} = \frac{1}{4}$$

所以：

$$P\{M > 0\} = 1 - \frac{1}{4} = \frac{3}{4}$$